

Predicción de Crecimiento de Adopción en Protocolos Blockchain a partir de Fundamentales *on-chain*

Michael Stiven Tabares Tobón, *Estudiante, Universidad de Antioquia*

María Fernanda Atencia Oliva, *Estudiante, Universidad de Antioquia*

Valeria Vásquez Barragán, *Estudiante, Universidad de Antioquia*

Jhon Sebastián Martínez Soto, *Estudiante, Universidad de Antioquia*

Resumen—Este documento describe el problema de investigación del proyecto, consistente en determinar si la información fundamental y el comportamiento histórico reciente de un protocolo de finanzas descentralizadas (*DeFi*), disponibles hasta la semana t , contienen suficiente señal para anticipar si dicho protocolo estará, durante la semana siguiente ($t + 1$), entre el 10 % de protocolos con mayor crecimiento relativo del valor total bloqueado (*Total Value Locked*, TVL). Se describe la base de datos construida a partir de la API pública de DeFiLlama, cuya unidad de observación es el par (*protocolo, semana*): 253 502 observaciones de 3 348 protocolos en 246 semanas, con una clase positiva de 10.0 %. Se detallan las variables, los datos faltantes, la estrategia de imputación, la codificación y un análisis exploratorio. El problema se formula como una clasificación binaria supervisada con validación temporal, cuya métrica principal es el área bajo la curva precisión-recall (PR-AUC). En coherencia con la literatura especializada, el diseño de características se orienta a los fundamentales de actividad (*Gross Merchandise Volume*, *fees*) y a variables derivadas dinámicas del TVL, y no solo a su nivel estático. Se presentan también las hipótesis del estudio, las limitaciones de los datos y una revisión de cuatro trabajos de aprendizaje de máquina sobre problemas afines.

Palabras clave—Finanzas descentralizadas (*DeFi*), *Total Value Locked* (TVL), *Gross Merchandise Volume* (GMV), clasificación supervisada, clases desbalanceadas, fundamentales *on-chain*, panel de datos, validación temporal.

I. DESCRIPCIÓN DEL PROBLEMA

A. Contexto del problema y utilidad de una solución basada en machine learning

Las finanzas descentralizadas (*DeFi*) constituyen un ecosistema de servicios financieros ejecutados sobre contratos inteligentes, sin intermediarios centralizados, en el que las métricas de actividad y de valor —la más usada de ellas el *Total Value Locked* (TVL), que cuantifica los activos depositados en los contratos de un protocolo— son públicas y, en principio, verificables *on-chain*, aunque su cálculo en los agregadores depende de adaptadores desarrollados por la comunidad y no está estandarizado [1]. Este ecosistema es altamente dinámico. El TVL agregado ha pasado por ciclos abruptos de crecimiento y contracción (Fig. 1a): cayó a $\approx 39\,000$ M USD a finales de 2022, subió a $\approx 166\,000$ M USD en 2025 y en 2026

llegó a estar $\approx 59\%$ por debajo de ese máximo. Además, el número de protocolos elegibles del panel (Sec. I-B) pasó de 513 a 1 498 entre 2022 y 2025 (Fig. 1b). En este entorno, el seguimiento manual de miles de protocolos es inviable, y existe una asimetría de información considerable entre los desarrolladores de los protocolos y sus usuarios [2].

El problema consiste en determinar si la información fundamental y el comportamiento histórico reciente de un protocolo —disponibles hasta la semana t — contienen suficiente señal para anticipar si ese protocolo estará, durante la semana siguiente ($t + 1$), entre el 10 % de protocolos con mayor crecimiento relativo del TVL de esa semana (definición formal en (2)). La utilidad de una solución basada en *machine learning* (ML) es triple:

- 1) **Escalabilidad.** Un modelo supervisado permite procesar de forma automática el panel completo de cada semana —en la mediana, 1 126 protocolos elegibles (Fig. 1b)—, algo inabordable manualmente.
- 2) **Detección de relaciones no lineales.** La relación entre los fundamentales *on-chain* y el valor de un protocolo es no lineal y muy volátil [2], y en problemas afines los modelos de ML superan a las referencias lineales y econométricas [3], [4].
- 3) **Marco de evaluación riguroso.** La formulación como clasificación binaria con validación temporal (Sec. I-C) permite responder de forma verificable si existe señal predictiva en los fundamentales, y cuáles son las variables más informativas.

El proyecto es de naturaleza académica y experimental: no se busca construir un sistema de *trading* ni predecir precios de tokens, sino estudiar la predictibilidad del crecimiento/adopción de protocolos a partir de fundamentales *on-chain*.

B. Composición de la base de datos

Fuente de datos. La base de datos se construye a partir de la API pública y gratuita de DeFiLlama (<https://api.llama.fi>), cuyos endpoints fueron verificados el 20/08/2026 [5]:

- GET /protocols — catálogo de protocolos y categorías.

- GET /protocol/{slug} — TVL histórico diario (total y por cadena).
- GET /summary/fees/{protocol} — *fees*/revenue diarios.
- GET /summary/dexs/{protocol} — volumen DEX diario.
- GET /overview/fees y /overview/dexs — protocolos que reportan *fees* o volumen.
- GET /v2/historicalChainTvl — TVL agregado del ecosistema (contexto de mercado).

Los datos se descargaron el 01/10/2026. DeFiLlama es también la fuente de TVL de trabajos académicos recientes sobre DeFi [2], [6], [7].

La granularidad nativa es diaria; el dataset se agrega a **semanas ISO** (cierre en domingo UTC): el TVL semanal es el valor al cierre de la semana, y los *fees* y el volumen DEX se suman sobre los siete días. La unidad de observación es el par (*protocolo*, *semana*): un protocolo aporta una fila por cada semana en la que tiene datos válidos.

Universo elegible y tamaño. El universo elegible $\mathcal{E}_t$ de la semana t está restringido a protocolos con TVL semanal ≥ 1 M USD y con al menos 8 semanas de historial previo; se excluyen los *exchanges* centralizados (categoría CEX), que DeFiLlama lista pero no son protocolos DeFi. El período va del 3 de enero de 2022 a la última semana ISO completa disponible en la descarga (27/09/2026). El panel resultante tiene 253 502 observaciones de 3 348 protocolos distintos en 246 semanas; el número de protocolos elegibles por semana varía entre 513 y 1 498, con mediana 1 126 (Fig. 1b).

Variable objetivo. Para cada protocolo $i \in \mathcal{E}_t$ se define el crecimiento logarítmico del TVL entre las semanas t y $t + 1$,

$$g_{i,t+1} = \ln\left(\frac{\text{TVL}_{i,t+1}}{\text{TVL}_{i,t}}\right), \quad (1)$$

y la etiqueta binaria

$$y_{i,t} = \begin{cases} 1, & \text{si } g_{i,t+1} \geq q_{0.9}(t+1), \\ 0, & \text{en otro caso,} \end{cases} \quad (2)$$

donde $q_{0.9}(t+1)$ es el percentil 90 de $\{g_{j,t+1} : j \in \mathcal{E}_t\}$. La etiqueta es relativa a la cohorte de cada semana, de modo que no depende de si todo el mercado sube o baja; por construcción, la clase positiva es cercana al 10 % (en la base final, 10.0 %). Si un protocolo deja de reportar TVL en $t + 1$, se le asigna $y_{i,t} = 0$ y no entra en el cálculo del percentil, para no descartar los casos de abandono.

Fundamentales priorizados. La literatura sobre valoración y predicción de protocolos DeFi converge en señalar que las métricas de **actividad** (distinguidas del capital inmóvil) son las más informativas. Metelski y Sobieraj [6] encuentran que el *Gross Merchandise Volume* (GMV) —el volumen transaccional agregado de un protocolo, análogo al volumen DEX de DeFiLlama— es la *única* variable que causa, en el sentido de Granger, la valoración futura, mientras que el TVL no la anticipa: es la valoración la que anticipa al TVL. En el mismo sentido, Ali [2], mediante análisis SHAP, encuentra que el GMV (≈ 0.062) supera al TVL (≈ 0.050) como determinante de la valoración; le siguen la clasificación

TABLA I
VARIABLES PREDICTORAS: ACTIVIDAD (GMV, *fees*, RAZONES) Y VARIABLES DERIVADAS DINÁMICAS DEL TVL. TODAS SE CALCULAN CON INFORMACIÓN $\leq$ CIERRE DE LA SEMANA t .

Variable	Cant.	Definición (tipo)
log_fees_week	1	$\ln(1 + \text{fees semanales})$; actividad (continua)
g_fees_1w, g_fees_4w	2	crecimiento de <i>fees</i> a 1 y 4 semanas (continua)
log_dex_vol_week	1	$\ln(1 + \text{volumen DEX}) \approx \text{GMV}$; actividad (continua)
ratio_fees_tvl	1	<i>fees</i> /TVL: eficiencia de monetización (continua)
ratio_vol_tvl	1	volumen DEX/TVL: utilización del capital (continua)
fees_tvl_rank_w	1	percentil de <i>fees</i> /TVL dentro de la semana (percentil)
g_tvl_1w...26w	6	crecimiento del TVL a 1, 2, 4, 8, 12 y 26 semanas (continua)
mom_2w...26w	4	<i>momentum</i> : media del crecimiento semanal en 2, 4, 12 y 26 semanas (continua)
accel, accel_12w	2	aceleración del crecimiento (continua)
vol_4w...26w	4	volatilidad: desv. estándar del crecimiento en 4, 8, 12 y 26 semanas (continua)
tvl_rank_w	1	percentil del TVL dentro de la semana (percentil)
Total: 24 variables numéricas. Además: 2 indicadoras (<i>has_fees</i> , <i>has_dex_vol</i>) y la categoría del protocolo en <i>one-hot</i> .		

del protocolo como DEX (≈ 0.039), la inflación de tokens (≈ 0.034 , con efecto negativo por dilución) y los ingresos totales (≈ 0.033). Fuera de DeFi, Gu *et al.* [8] concluyen que los predictores dominantes del retorno de sección cruzada son el *momentum*, la liquidez y la volatilidad: variables dinámicas, no niveles estáticos. Un informe de industria de Greenfield Capital [9] matiza este resultado: con *Random Forest* sobre 77 protocolos, encuentra que desde 2024 el TVL y los *fees* tienen importancias similares en el horizonte de 6 meses ($\approx 19.7\%$ y $\approx 19.2\%$), por encima del volumen DEX ($\approx 11.8\%$), aunque con un diseño contemporáneo, no predictivo.

Por ello, el panel incorpora (i) características de actividad —el GMV/volumen DEX y *fees* semanales, su crecimiento a 1 y 4 semanas y su razón respecto al TVL (eficiencia de monetización y utilización del capital)— y (ii) variables derivadas del TVL que añaden dinamismo: crecimiento a 1/2/4/8/12/26 semanas, *momentum* a 2/4/12/26 semanas, aceleración y volatilidad a 4/8/12/26 semanas, junto con la posición relativa (*rank*) del TVL dentro de la semana. En total son 24 variables numéricas (Tabla I), a las que se suman 2 variables indicadoras de disponibilidad y la categoría del protocolo. Todas se calculan con información disponible hasta el cierre de la semana t .

Datos faltantes e imputación. No todos los protocolos reportan *fees*, y el volumen DEX solo existe para los protocolos de intercambio; por eso estas variables concentran los faltantes (Tabla II). La estrategia de imputación es: (i) los *fees* o el volumen no reportados se imputan como 0 y se agregan las indicadoras *has_fees* y *has_dex_vol*, para distinguir “no reporta” de “reporta cero”; (ii) los huecos puntuales en la serie diaria de TVL se rellenan hacia adelante hasta 7 días,

TABLA II
ESTADÍSTICAS DESCRIPTIVAS Y PORCENTAJE DE DATOS FALTANTES
(ANTES DE IMPUTAR) DE VARIABLES SELECCIONADAS

Variable	Media	Mediana	Desv.	% falt.
$g_{i,t+1}$ (objetivo)	-0.0270	-0.00487	0.309	0.2
g_tvl_1w	0.00457	-0.00312	0.429	0.1
$\log_fees_week$	9.50	9.93	3.36	68.7
$\log_dex_vol_week$	15.1	15.1	3.51	81.3
$ratio_fees_tvl$	0.00422	0.000692	0.0536	68.7
vol_12w	0.188	0.104	0.509	4.6

Clase positiva ($y_{i,t} = 1$): 10.0 % de las observaciones.


sin rellenar nunca hacia atrás —a diferencia de [2]—, para no introducir información futura; (iii) cuando una ventana es más larga que el historial disponible (por ejemplo, 26 semanas en un protocolo con 10), se imputa la mediana transversal de la semana, como en [8]; y (iv) los protocolos con menos de 8 semanas de historial quedan fuera por el criterio de elegibilidad.

Codificación. Los montos (*fees*, volumen) se transforman con $\ln(1+x)$ por su fuerte asimetría, y los crecimientos se calculan como diferencias de $\ln(1+x)$, lo que los deja definidos aun cuando el valor previo es 0. Las posiciones relativas se codifican como percentiles dentro de la semana, en $[0, 1]$. Las variables continuas se recortan en los percentiles 1 y 99 de cada semana para limitar valores extremos, sin modificar la variable objetivo. La categoría del protocolo (DEX, *Lending*, *Liquid Staking*, etc.) se codifica en *one-hot*, agrupando en “Otros” las categorías con menos de 20 protocolos. La etiqueta es binaria (0/1), y el escalamiento estándar que requieren modelos como SVM o redes neuronales se ajustará solo con el conjunto de entrenamiento.

Análisis exploratorio. La Tabla II resume las variables principales y su porcentaje de faltantes; la Fig. 1 muestra la evolución del TVL agregado y del número de protocolos elegibles, y la Fig. 2, la distribución del crecimiento semanal y la correlación entre predictores. La variable objetivo continua $g_{i,t+1}$ tiene mediana -0.00487 y colas pesadas (curtosis en exceso de 547); el umbral semanal $q_{0.9}$ promedia 0.0838 y varía entre -0.0569 y 0.332 , mientras que la clase positiva se mantiene entre 9.9 % y 10.4 % por semana. Las variables de actividad concentran los faltantes: los *fees* faltan en 68.7 % de las observaciones y el volumen DEX en 81.3 %, lo que justifica las indicadores de disponibilidad. La correlación de Spearman (Fig. 2b) muestra variables redundantes: cada mom_kw es igual a g_tvl_kw/k , y $accel$ y $accel_12w$ son combinaciones lineales de otras variables, por lo que la matriz de predictores tiene rango 18 de 24; estas variables son candidatas a eliminarse en el Entregable II. Entre variables distintas, el par más correlacionado es $ratio_fees_tvl$ y $fees_tvl_rank_w$ ($\rho = 0.98$). Un umbral $q_{0.9}$ negativo corresponde a semanas de caída generalizada, en las que incluso el decil superior pierde TVL; aun así, la etiqueta relativa conserva cerca de 10 % de positivos en cualquier régimen de mercado. Además, $fees_tvl_rank_w$ es el percentil semanal de $ratio_fees_tvl$, por lo que ese par es casi redundante por construcción.



(a) TVL agregado del ecosistema por semana (eje y : miles de millones de USD).



(b) Protocolos del universo elegible $\mathcal{E}_t$ por semana (eje y : número de protocolos).


Fig. 1. Composición temporal de la base de datos.

Limitaciones de los datos. El TVL se calcula como la cantidad de tokens depositados multiplicada por su precio, de modo que parte de su crecimiento refleja variaciones de precio y no nuevos depósitos; la etiqueta relativa por semana atenúa el efecto general del mercado, pero no la distinta exposición de cada protocolo a activos como ETH. Además, el cálculo depende de adaptadores comunitarios sin estandarizar, algunos de los cuales consultan servidores externos, y un mismo depósito puede contarse en más de un protocolo [1]. Por último, los protocolos que dejan de operar dejan de reportar datos, lo que puede introducir sesgo de supervivencia.


C. Paradigma de aprendizaje

El problema se aborda con aprendizaje **supervisado**, como una tarea de **clasificación binaria** sobre el panel (protocolo, semana): a partir de las variables de la semana t (Tabla I) se predice la etiqueta $y_{i,t}$ de (2). Se prefiere la clasificación a la regresión del crecimiento porque $g_{i,t+1}$ tiene colas muy pesadas (Fig. 2a), y predecir si un protocolo estará en el decil superior es más estable y responde directamente la pregunta de investigación. Gu *et al.* [8] usan una lógica similar al ordenar los activos en deciles según su predicción, y Jaquart *et al.* [4] formulan una clasificación binaria análoga: si cada criptomoneda superará la mediana de rendimiento del día siguiente.

Como la clase positiva representa cerca del 10 % de las observaciones, la métrica principal es el área bajo la curva



(a) Distribución de $g_{i,t+1}$ con el umbral promedio $q_{0.9}$; se omite el 1% de valores más extremos (eje y : frecuencia, en escala logarítmica).



(b) Correlación de Spearman entre las 24 variables numéricas.

Fig. 2. Variable objetivo y relación entre predictores.

precisión–recall (PR-AUC), estimada como la precisión promedio

$$AP = \sum_n (R_n - R_{n-1}) P_n, \quad (3)$$

donde P_n y R_n son la precisión y el *recall* en el n -ésimo umbral. A diferencia del AUC-ROC, la PR-AUC no se ve dominada por la clase mayoritaria, y un clasificador aleatorio obtiene un valor igual a la prevalencia (≈ 0.10). El desbalance se tratará en el Entregable II con ponderación de clases o técnicas de sub y sobremuestreo, aplicadas solo al conjunto de entrenamiento.

La validación es temporal, sin mezclar semanas futuras en el entrenamiento: entrenamiento de 2022 a 2024, validación en 2025 y prueba en 2026. Como la etiqueta de la semana t usa el TVL de $t+1$, se descarta la última semana de cada bloque para evitar solapamiento entre conjuntos. El año de prueba coincide con una fase de contracción del TVL (Fig. 1a), lo que permitirá evaluar la robustez de los modelos ante un cambio de régimen.

D. Hipótesis

- **H1:** las variables de actividad (*fees*, volumen DEX y sus razones con el TVL) aportan más poder predictivo que las variables basadas solo en el nivel del TVL.
- **H2:** los modelos no lineales (ensambles de árboles, redes neuronales) superan en PR-AUC a un modelo lineal de referencia (regresión logística).

H1 se evaluará comparando modelos entrenados con cada grupo de variables, y H2, comparando los modelos del Entregable II contra la regresión logística.

II. ESTADO DEL ARTE

Se revisaron artículos de revista (2020–2026) de *machine learning* que usaran la misma fuente de datos (DeFiLlama) o variables equivalentes (TVL, GMV, *fees*), o que resolvieran el mismo tipo de problema: predecir el desempeño relativo de muchos activos. No encontramos trabajos de ML que usen DeFiLlama para predecir el crecimiento del TVL, que es el vacío que aborda este proyecto.

A. Trabajos revisados

En la Tabla III, Ali [2] es el trabajo más cercano en datos (DeFiLlama y las mismas familias de variables), aunque predice la valoración y no el crecimiento del TVL; Ghosh *et al.* [3] muestran que los ensambles de árboles predicen bien los precios de tokens DeFi; y Gu *et al.* [8] y Jaquart *et al.* [4] son los más cercanos en estructura: predicen el desempeño relativo en un panel de muchos activos, y los segundos lo formulan, como nosotros, como una clasificación binaria respecto a la cohorte de cada periodo.

B. Definición de métricas

RMSE, MAE, R^2 , exactitud, precisión, *recall*, F1 y AUC-ROC son métricas estándar que no se redefinen aquí, y la PR-AUC se definió en (3). Para las demás, y_t es el valor real, $\hat{y}_t$ el predicho, $\bar{y}$ la media real y N el número de observaciones. Gu *et al.* [8] usan un R^2 fuera de muestra que compara contra una predicción de cero, no contra la media histórica:

$$R_{oos}^2 = 1 - \frac{\sum (r_{i,t+1} - \hat{r}_{i,t+1})^2}{\sum r_{i,t+1}^2}. \quad (4)$$

Ghosh *et al.* [3] usan la eficiencia de Nash-Sutcliffe (NSE), el índice de Theil (TI) y el índice de concordancia (IA):

$$NSE = 1 - \frac{\sum (\hat{y}_t - y_t)^2}{\sum (y_t - \bar{y})^2}, \quad (5)$$

$$TI = \frac{\sqrt{\frac{1}{N} \sum (\hat{y}_t - y_t)^2}}{\sqrt{\frac{1}{N} \sum \hat{y}_t^2} + \sqrt{\frac{1}{N} \sum y_t^2}}, \quad (6)$$

$$IA = 1 - \frac{\sum (\hat{y}_t - y_t)^2}{\sum (|\hat{y}_t - \bar{y}| + |y_t - \bar{y}|)^2}, \quad (7)$$

y la exactitud direccional $DA = \frac{1}{N} \sum_t D_t$, con $D_t = 1$ si $(y_{t+1} - y_t)(\hat{y}_{t+1} - y_t) \geq 0$ y $D_t = 0$ en otro caso. NSE e IA cercanos a 1 y TI cercano a 0 indican mejores predicciones. La razón de Sharpe [4], [8] es $SR = \bar{r}_p / \sigma_p$: la media del

TABLA III
TRABAJOS DE APRENDIZAJE DE MÁQUINA REVISADOS

Trabajo	Paradigma	Técnica y datos	Validación	Métricas	Resultados
Ali (2026) [2]	Regresión supervisada (valoración)	<i>Super Learner</i> apilado (<i>Extra Trees</i> , CatBoost y SVR; KNN como meta-aprendiz) con Optuna. 30 protocolos DeFi, 5 370 observaciones diarias de 2022 (DeFiLlama, TokenTerminal y DappRadar).	Validación cruzada de 10 pliegues para elegir algoritmos; validación cruzada temporal de panel con ventana expandida.	RMSE, MAE, R^2 ; Wilcoxon.	RMSE = 0.085, MAE = 0.065, $R^2 = 0.97$; error 25–36 % menor que el de los modelos alternativos ($p < 0.01$). SHAP: GMV > TVL > clase DEX.
Ghosh <i>et al.</i> (2023) [3]	Regresión supervisada (precio diario)	ISOMAP + <i>Gradient Boosting</i> y UMAP + <i>Random Forest</i> con indicadores técnicos, macroeconómicos y de medios. Precios diarios de 4 tokens DeFi y 4 NFT, 2020–2022.	Partición 85/15; <i>GridSearchCV</i> ; comparación con DT, SVR, ARIMA y SARIMA (Kruskal-Wallis).	NSE, TI, IA, DA.	En prueba, NSE de 0.85 a 0.98 y DA de 0.89 a 0.96 en los tokens DeFi; superan a los modelos de comparación.
Gu <i>et al.</i> (2020) [8]	Regresión supervisada (retorno mensual)	OLS, ENet, PCR, PLS, GLM, RF, GBRT y redes neuronales de 1 a 5 capas; cerca de 30 000 acciones y 920 predictores, 1957–2016.	Entrenamiento 1957–1974, validación 1975–1986 y prueba 1987–2016; reentrenamiento anual.	R^2_{oos} ; Diebold-Mariano; Sharpe.	Árboles y redes: R^2_{oos} mensual de 0.33 a 0.40 % (OLS con 3 variables: 0.16 %); cartera larga-corta por deciles con Sharpe de 1.35.
Jaquart <i>et al.</i> (2022) [4]	Clasificación binaria supervisada (desempeño relativo)	LSTM, GRU, TCN, GBC, RF y regresión logística sobre los retornos de los 90 días previos; 100 criptomonedas de mayor capitalización (CoinGecko), 2018–2022. Etiqueta: retorno del día siguiente $\geq$ mediana.	5 periodos móviles de 800 días: entrenamiento (500), validación de hiperparámetros (150) y prueba (150).	Exactitud; prueba binomial; Sharpe.	Exactitud de 52.9 % (LR) a 54.2 % (RF); 57.5–59.5 % en el 10 % de predicciones más confiables. Sharpe tras costos: 3.23 (LSTM) frente a 1.33 del mercado.

retorno (en exceso) de una cartera dividida por su desviación estándar. Las pruebas de Wilcoxon, Kruskal-Wallis y Diebold-Mariano contrastan si las diferencias de error entre modelos son significativas, y la binomial, si la exactitud supera el 50 % del azar.

C. Síntesis y contribución al problema

La literatura apunta en tres direcciones: la señal útil está en la dinámica y la actividad (*momentum*, volatilidad, *fees*, volumen) más que en el nivel del TVL; los métodos no lineales superan a los lineales, aunque la señal es débil — en [4], la exactitud pasa de 52.9 % con regresión logística a 54.2 % con RF, frente al 50 % del azar—, por lo que la PR-AUC se comparará con la de un clasificador aleatorio y la de la regresión logística; y la validación debe respetar el orden temporal. Tres de los cuatro trabajos formulan una regresión; nuestro proyecto sigue la lógica de [4] con una clasificación relativa: ¿estará el protocolo en el decil superior de crecimiento la próxima semana?

- [5] DeFiLlama, “DeFiLlama API—documentation (free API),” 2026, accedido: 20 de agosto de 2026. [Online]. Available: <https://api-docs.defillama.com/lms-free.txt>
- [6] D. Metelski and J. Sobieraj, “Decentralized finance (DeFi) projects: A study of key performance indicators in terms of DeFi protocols’ valuations,” *International Journal of Financial Studies*, vol. 10, no. 4, 2022, art. no. 108, doi: 10.3390/ijfs10040108.
- [7] M. Grande and J. Borondo, “Trust as a driver in the DeFi market: Leveraging TVL/MCAP bands as confidence indicators to anticipate price movements,” *Finance Research Letters*, vol. 75, 2025, art. no. 106705, doi: 10.1016/j.frl.2024.106705.
- [8] S. Gu, B. Kelly, and D. Xiu, “Empirical asset pricing via machine learning,” *The Review of Financial Studies*, vol. 33, no. 5, pp. 2223–2273, 2020, doi: 10.1093/rfs/hhaa009.
- [9] F. Machart and M. Dominiak, “Do fundamentals drive DeFi valuations? Analyzing evolving market efficiency with random-forest models (2021–2025),” Greenfield Capital, Industry research report, Nov. 2025. [Online]. Available: https://greenfieldcapital.com/wp-content/uploads/2025/11/202511_Greenfield_DeFi_Fundamentals_Report.pdf

REFERENCIAS

- [1] P. Saggese, M. Fröwis, S. Kitzler, B. Haslhofer, and R. Auer, “Towards verifiability of total value locked (TVL) in decentralized finance,” arXiv preprint arXiv:2505.14565, May 2025.
- [2] G. M. Ali, “Digital asset analytics for DeFi protocol valuation: An explainable Optuna-tuned super learner ensemble framework,” *Journal of Risk and Financial Management*, vol. 19, no. 1, 2026, art. no. 63, doi: 10.3390/jrfm19010063.
- [3] I. Ghosh, E. Alfaro-Cortés, M. Gámez, and N. García-Rubio, “Prediction and interpretation of daily NFT and DeFi prices dynamics: Inspection through ensemble machine learning & XAI,” *International Review of Financial Analysis*, vol. 87, 2023, art. no. 102558, doi: 10.1016/j.irfa.2023.102558.
- [4] P. Jaquart, S. Köpke, and C. Weinhardt, “Machine learning for cryptocurrency market prediction and trading,” *The Journal of Finance and Data Science*, vol. 8, pp. 331–352, 2022, doi: 10.1016/j.jfds.2022.12.001.